Smart Waste Classifier

Musso Lorenzo (2049518), Pietrangeli Giulia (2057291)

May 2025

Sommario

Il progetto presentato consiste nello sviluppo di un sistema di classificazione automatica dei rifiuti basato sull'elaborazione di immagini. L'obiettivo principale è identificare la categoria corretta di un rifiuto a partire da una sua fotografia, al fine di supportare un corretto processo di smaltimento e riciclaggio. Il sistema è composto da diverse fasi:

- **Acquisizione e preparazione dei dati**: unione di due dataset esistenti e successiva pulizia e riorganizzazione.
- **Addestramento dei modelli**: utilizzo di CNN e di un classificatore lineare basato su regressione logistica.
- **Interfaccia grafica**: realizzata in Python tramite `Gradio`.

1 Introduzione

La classificazione automatica dei rifiuti mediante visione artificiale è un'area di ricerca in rapido sviluppo, volta a rendere più efficiente la raccolta differenziata e a ridurre l'impatto ambientale. Un progetto innovativo su questo tema è **TrashNet**, sviluppato da Thung e Yang, che ha messo a disposizione un dataset di immagini in sei classi di rifiuto e ha confrontato SVM e CNN ottenendo il 63 % di accuratezza con l'SVM e solo il 22 % con la CNN, a causa di iperparametri non ottimali [3]. Successivamente, molte ricerche hanno sfruttato tecniche di **transfer learning** su TrashNet, applicando architetture pre-addestrate come DenseNet121 e raggiungendo fino al 95 % di accuratezza [1]. Altri autori hanno proposto reti leggere per l'implementazione in tempo reale su dispositivi a bassa potenza: ad esempio, un modello CNN "semplice ed efficiente" ha ottenuto il 90,7 % di accuratezza su TrashNet, dimostrando la fattibilità del deploy in ambienti embedded [2]. Il nostro progetto mira a sviluppare un sistema di classificazione dei rifiuti semplice con l'obiettivo di supportare pratiche di riciclo e smaltimento corretto.

2 Dataset

Per addestrare e valutare i modelli di classificazione sono stati utilizzati due dataset pubblici: *TrashNet* e *Garbage Classification*. I dati sono stati unificati e riorganizzati per ottenere un insieme coerente e bilanciato di immagini, suddivise per tipologia di rifiuto.

2.1 Unione dei dataset e pulizia

La fusione delle immagini provvede a:

- copiare le immagini del dataset *TrashNet* in una directory comune;
- unire le classi del dataset *Garbage Classification*, gestendo possibili conflitti di nomi tramite un sistema di rinomina con prefissi specifici;
- accorpare classi semanticamente simili (*paper* e *cardboard*; *brown-glass*, *green-glass*, *white-glass* $\rightarrow$ *glass*).

Al termine della fusione, è stata effettuata una fase di pulizia per rimuovere eventuali immagini corrotte o non leggibili. Tale procedura utilizza OpenCV per verificare l'integrità di ciascun file immagine.

2.2 Categorie finali

Al termine delle operazioni di unione e pulizia, il dataset finale risulta organizzato in sette categorie principali:

- **battery**
- **biological**
- **clothes**
- **glass**
- **metal**
- **paper**
- **plastic**

Tutte le immagini presenti nel dataset sono state riclassificate secondo queste categorie, in modo da garantire uniformità e coerenza nell'addestramento dei modelli. Questa scelta ha consentito di ridurre la complessità del task di classificazione, evitando ambiguità tra classi troppo specifiche o ridondanti, e facilitando la generalizzazione del sistema.

Le categorie selezionate coprono le principali tipologie di rifiuto comunemente coinvolte nei processi di smaltimento e riciclaggio, sia a livello globale che in particolare in Italia. Queste categorie sono rappresentative delle linee guida

adottate nei sistemi di raccolta differenziata presenti sul territorio nazionale, che prevedono una gestione separata per materiali come carta, plastica, vetro e metalli. Inoltre, le categorie scelte sono abbastanza ampie da adattarsi facilmente ai diversi modelli e sistemi di smaltimento adottati a livello regionale, che possono variare leggermente nelle specifiche classificazioni, ma che in generale seguono principi comuni di gestione dei rifiuti.

Come mostrato nella Figura 1, la distribuzione del dataset risultante non è perfettamente bilanciata. In particolare, la classe **clothes** costituisce una porzione dominante, con il **36,1%** delle immagini totali. Seguono le classi **glass** (17%) e **paper** (16,6%), mentre le restanti categorie — **plastic** (9,1%), **metal** (8%), **biological** (6,7%) e **battery** (6,4%) — sono significativamente meno rappresentate.

Tale distribuzione riflette la composizione dei dataset originali, che già presentavano uno sbilanciamento iniziale.

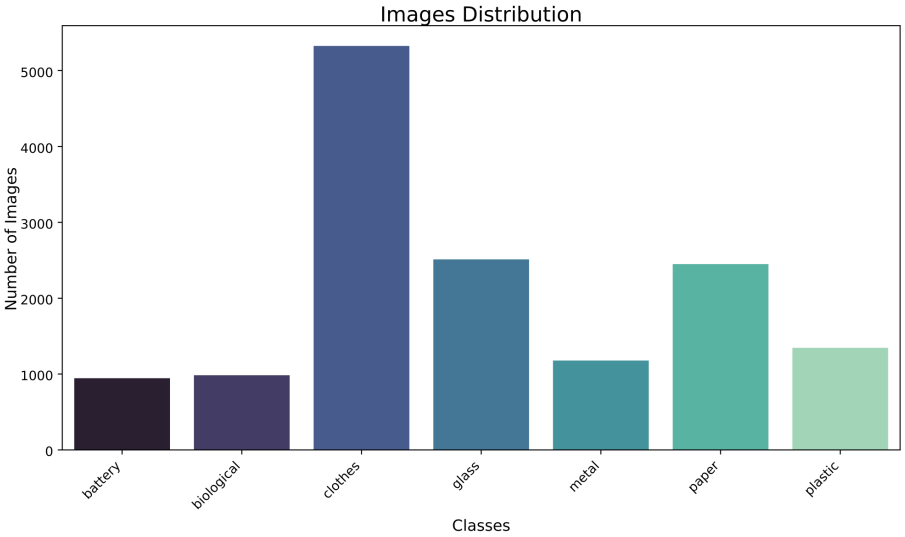

Figura 1: Distribuzione percentuale delle immagini per ciascuna classe

Tuttavia, questa disomogeneità potrebbe influenzare le prestazioni dei modelli di classificazione, che tendono a favorire le classi maggioritarie, trascurando quelle meno rappresentate. Per mitigare tale effetto, si possono applicare diverse strategie durante la fase di training, tra cui tecniche di *data augmentation*, e di *bilanciamento delle classi*. Queste soluzioni possono migliorare l'equità delle predizioni, portando a una maggiore robustezza del sistema.

3 Modelli e gestione dei dati

Nel progetto sono stati impiegati due modelli principali per la classificazione automatica delle immagini di rifiuti: una rete neurale convoluzionale (CNN) e un classificatore lineare basato su regressione logistica (LR-SGD), quest'ultimo addestrato sulle feature estratte dalla CNN.

3.1 Rete neurale convoluzionale (CNN)

La **CNN** è una rete convoluzionale costruita da quattro blocchi convoluzionali con ReLU e max pooling, seguiti da due layer completamente connessi (FC). La rete è strutturata come segue:

- **Input:** immagini RGB ridimensionate a 128×128 pixel;
- **Convoluzioni:** 4 layer convoluzionali con kernel 3×3 e padding 1;
- **Pooling:** max pooling 2×2 dopo ogni convoluzione;
- **Dropout:** applicato prima del primo layer fully-connected per ridurre l'overfitting;
- **Output:** softmax finale con numero di classi pari a quelle presenti nel dataset.

L'addestramento è stato eseguito con ottimizzatore `Adam`, tasso di apprendimento iniziale pari a 0.001 e funzione di perdita `FocalLoss`, una variante della cross entropy utile per gestire class imbalance. Il dataset è stato suddiviso in **80% per il training** e **20% per il test**, e le immagini sono state trasformate tramite tecniche di *data augmentation* per aumentare la robustezza del modello.

3.2 Data Augmentation

Per migliorare la generalizzazione del modello e ridurre l'overfitting, durante il training vengono applicate diverse tecniche di *data augmentation*. Queste trasformazioni introducono variazioni artificiali nelle immagini, simulando condizioni diverse rispetto a quelle presenti nel dataset originale. Le principali tecniche adottate sono:

- **Random Resized Crop**: ritaglio casuale con ridimensionamento, per ridurre la sensibilità alla posizione dell'oggetto.
- **Random Horizontal Flip** e **Random Rotation**: introducono variabilità angolare, simulando orientazioni differenti.
- **Color Jitter**: modifica casuale di luminosità, contrasto, saturazione e tonalità per adattarsi a condizioni di luce variabili.
- **Random Perspective**: altera la geometria dell'immagine per simulare diverse prospettive.

- **Gaussian Blur**: riduce il rumore e simula imperfezioni visive.
- **Random Erasing**: occlude casualmente porzioni di immagine, rendendo il modello più robusto a informazioni mancanti.

L'applicazione casuale di queste trasformazioni consente di simulare numerose variazioni reali, migliorando le performance su dati non visti.

3.3 Fine-tuning e estrazione delle feature

Dopo un primo addestramento, la rete CNN è stata sottoposta a **fine-tuning**, mantenendo la stessa architettura ma riducendo il learning rate, con l'obiettivo di migliorare ulteriormente le performance. Successivamente, la rete fine-tunata è stata utilizzata come *feature extractor*: rimuovendo gli strati fully-connected, le feature ottenute dall'ultimo strato convoluzionale (dopo il flattening) sono state estratte per ciascuna immagine.

Queste rappresentazioni vettoriali sono poi state normalizzate e utilizzate per addestrare il classificatore lineare basato su regressione logistica **LR-SGD**, al fine di valutare la qualità delle feature apprese dalla rete convoluzionale.

3.4 Classificatore probabilistico LR-SGD

Le feature estratte dalla rete CNN sono state standardizzate utilizzando uno `StandardScaler` e utilizzate per addestrare il classificatore lineare basato su regressione logistica (LR-SGD) implementato con `SGDClassifier` di scikit-learn, con loss `log_loss`. L'LR-SGD è stato addestrato in modalità iterativa per 10 epoche, con validazione su un sottoinsieme del dataset (`train_test_split` con stratificazione).

3.5 Gestione dello sbilanciamento tra classi

Per mitigare l'effetto di classi sbilanciate, sono stati utilizzati i seguenti approcci:

- **Pesi di classe bilanciati** nella `FocalLoss`, calcolati tramite la funzione `compute_class_weight` di scikit-learn, che permettono di ponderare maggiormente le classi meno rappresentate durante l'addestramento.
- **Sampler pesato** (`WeightedRandomSampler`) per garantire che ogni classe venga campionata proporzionalmente alla sua frequenza inversa, favorendo così l'apprendimento delle classi minoritarie.

3.6 Metriche Utilizzate

Per valutare le prestazioni del modello durante training e validazione, sono state utilizzate diverse metriche, ognuna con un ruolo specifico nell'analisi:

- **Loss**: Misura lo scarto tra le previsioni e i valori reali. Una loss bassa indica un buon apprendimento. Viene monitorata sia in training che in validazione.

- **Accuracy**: Percentuale di previsioni corrette. È utile con classi bilanciate, ma può risultare ingannevole in presenza di squilibri.
- **Log Loss** (*cross-entropy*): Utile per classificazione probabilistica. Penalizza fortemente le previsioni errate molto sicure.
- **Precision**: Rapporto tra veri positivi e previsioni positive. Indica quante delle predizioni positive sono corrette. È importante quando i falsi positivi sono costosi.
- **Recall**: Rapporto tra veri positivi e positivi reali. Misura la capacità del modello di non perdere istanze rilevanti.
- **F1-score**: Media armonica tra precision e recall. Utile in presenza di classi sbilanciate per offrire una valutazione equilibrata.

L'uso combinato di queste metriche consente una valutazione più completa delle performance, anche in contesti con distribuzione irregolare delle classi.

4 Analisi Comparativa dei Risultati

4.1 Confronto delle Prestazioni: CNN vs LR-SGD

Vengono confrontate le prestazioni ottenute dai modelli CNN e LR-SGD sulla base delle principali metriche di classificazione: accuracy, precision, recall e F1-score. Le tabelle seguenti riportano i risultati per ciascuna classe.

Tabella 1: Metriche di valutazione per il modello CNN

Classe	**Precision**	**Recall**	**F1-score**	**Support**
battery	0.585	0.940	0.721	201
biological	0.508	0.960	0.664	200
clothes	0.976	0.690	0.808	1061
glass	0.890	0.598	0.715	485
metal	0.554	0.833	0.665	221
paper	0.801	0.728	0.763	497
plastic	0.626	0.856	0.723	284
Macro avg	0.706	0.801	0.723	2949
Weighted avg	0.809	0.743	0.751	2949
Accuracy		0.743		

Tabella 2: Metriche di valutazione per il modello LR-SGD

Classe	**Precision**	**Recall**	**F1-score**	**Support**
battery	0.579	0.845	0.687	174
biological	0.555	0.865	0.676	193
clothes	0.905	0.806	0.853	1079
glass	0.703	0.590	0.642	476
metal	0.502	0.571	0.534	252
paper	0.669	0.569	0.615	529
plastic	0.527	0.634	0.576	246
Macro avg	0.634	0.697	0.655	2949
Weighted avg	0.722	0.701	0.704	2949
Accuracy		0.701		

Il modello CNN ha ottenuto complessivamente risultati migliori rispetto all'LR-SGD. L'accuratezza globale è più alta (0.743 contro 0.701), e anche le metriche macro e weighted mostrano un vantaggio in termini di F1-score e recall. In particolare, la CNN si distingue nella classificazione delle classi *metal*, *plastic* e *paper*, mostrando una maggiore capacità di individuare correttamente le istanze positive. L'LR-SGD, invece, ottiene buoni risultati nella classe *clothes*, ma tende a performare peggio nelle classi meno rappresentate.

4.2 Confronto tramite Matrici di Confusione

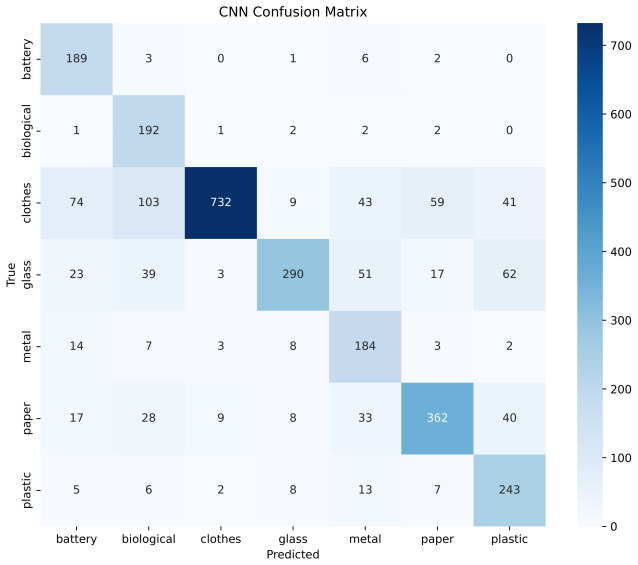

Figura 2: Matrice di Confusione – CNN

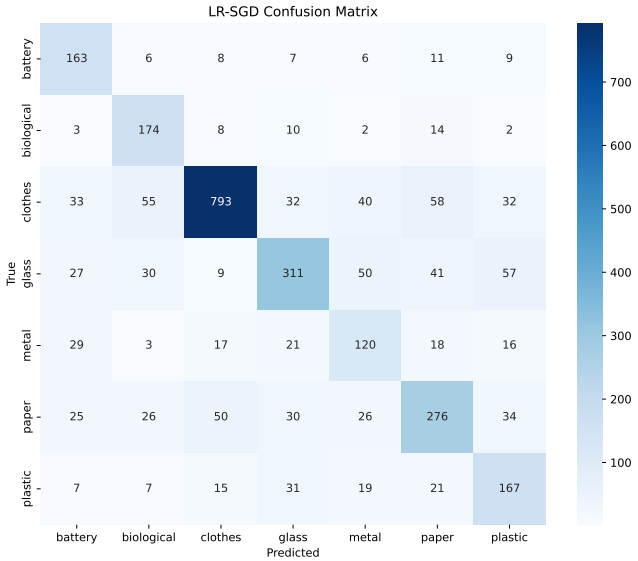

Figura 3: Matrice di Confusione – LR-SGD

La CNN mostra una **precisione complessiva superiore**, con valori più elevati sulla diagonale principale, indicativi di una classificazione corretta più frequente. Entrambi i modelli presentano difficoltà con le classi *clothes* e *paper*, che vengono spesso confuse tra loro. Tuttavia, la CNN evidenzia un problema aggiuntivo con la classe *clothes*, frequentemente scambiata con *biological* e *battery*. Al contrario, l'LR-SGD distribuisce gli errori più uniformemente tra le classi, mostrando una maggiore robustezza nella classe *clothes*.

4.3 Accuratezza e Perdita durante il Training

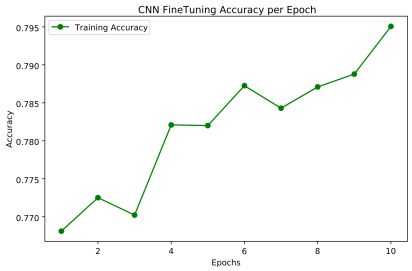

(a) CNN – Fine Tuning Accuracy

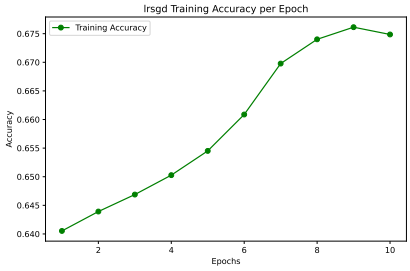

(b) LR-SGD – Training Accuracy

Figura 4: Andamento dell'accuratezza durante il fine tuning per CNN e l'addestramento per LR-SGD

La CNN mostra un miglioramento costante dell'accuratezza durante l'addestramento, suggerendo un processo di apprendimento efficace e progressivo. In particolare, l'accuratezza cresce da circa 0.77 a 0.795, indicando una continua ottimizzazione del modello. Al contrario, l'LR-SGD presenta un'accuratezza piuttosto stabile e bassa, variando tra 0.64 e 0.675.

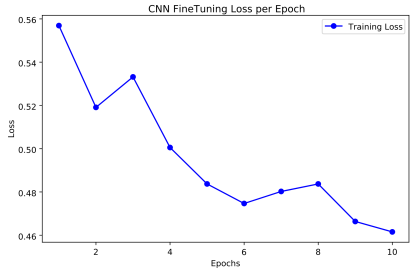

(a) CNN – Fine Tuning Loss

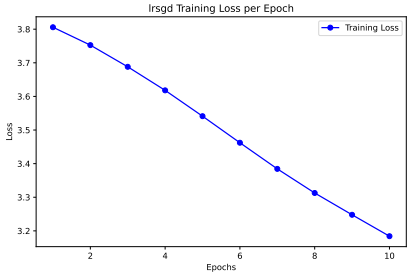

(b) LR-SGD – Training Loss

Figura 5: Andamento della perdita durante il fine tuning per CNN e l'addestramento per LR-SGD

Anche nella funzione di perdita (loss), la CNN evidenzia un chiaro miglioramento, con una diminuzione progressiva e costante da circa 0.46 a 0.56, segno di una continua ottimizzazione del modello. L'LR-SGD, invece, mantiene una loss significativamente più alta e in lenta discesa, da 3.2 a 3.8, indicando un'ottimizzazione meno efficiente e un adattamento più lento ai dati.

5 Implementazione dell'Interfaccia Utente

L'interfaccia utente dello *Smart Waste Classifier* è stata sviluppata utilizzando la libreria `Gradio`, che permette di costruire facilmente applicazioni web interattive per i modelli di machine learning. L'obiettivo principale di questa interfaccia è fornire un'esperienza utente semplice ed intuitiva, che consenta di caricare un'immagine di un rifiuto e ottenere la sua classificazione in tempo reale.

5.1 Descrizione Generale dell'Interfaccia

L'interfaccia è costituita da diversi elementi visivi e funzionali, tra cui:

- Un'area di caricamento per l'immagine del rifiuto.
- Un riquadro che mostra i risultati delle predizioni dei due modelli: uno basato su CNN e uno basato su LR-SGD.
- Un'area che visualizza il risultato finale, che indica la categoria del rifiuto, un'icona corrispondente e una barra di confidenza che rappresenta quanto il modello è sicuro della sua predizione.

L'interfaccia è strutturata per essere semplice da usare: l'utente carica un'immagine e ottiene rapidamente i risultati delle classificazioni.

5.2 Funzionalità Principali

Le principali funzionalità dell'interfaccia sono:

- **Caricamento immagine**: L'utente può caricare un'immagine di un rifiuto (ad esempio, una bottiglia di plastica, una lattina, ecc.).
- **Classificazione CNN**: Il modello CNN analizza l'immagine e restituisce una predizione della categoria del rifiuto, accompagnata da un livello di confidenza.
- **Classificazione LR-SGD**: Il modello LR-SGD esegue una predizione basata su un insieme di caratteristiche estratte dall'immagine, restituendo anch'esso una categoria con un livello di confidenza.
- **Risultato Finale**: L'interfaccia confronta le predizioni della CNN e dell'LR-SGD, e presenta la categoria finale con un'icona corrispondente, insieme alla barra di confidenza che rappresenta la certezza della predizione finale.

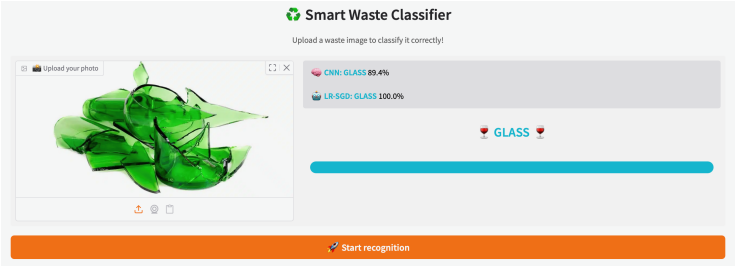

Figura 6: Interfaccia grafica del sistema di classificazione dei rifiuti.

Riferimenti bibliografici

[1] Okan Bircanoğlu et al. Recycling waste classification using optimized convolutional neural networks. *Computers, Environment and Urban Systems*, 85:101567, 2023.

[2] Jeet Prajapati et al. A comparative analysis of garbage classification using resnet50, xception and densenet121 architecture. *Lecture Notes in Networks and Systems*, 967:383–402, 2024.

[3] Gary Thung and Mindy Yang. Trashnet: Automated waste classification with deep learning. *GitHub*, 2016.